



DRAM&HBM hybrid pooling, memory semantic interface, high-performance cross-machine memory direct access

MemFabric Hybrid

Zexin Jian

Institute of Computing Technology, Chinese Academy of Sciences

jianzexin25z@ict.ac.cn

华为韬定律	2
Background	4
Challenges	5
模型增长趋势	6
Huawei CloudMatrix384	7
Design	9
MemFabric Architecture	10
多层设计	12
Design 1: Global Virtual Address	13
Design 2: 跨机跨介质直接访问	15
Takeaways & Discussion	16
Takeaways & Discussion	17

华为创新性地提出了“逻辑折叠(LogicFolding)”等核心技术，构建了贯穿器件、电路、芯片到系统层面的多层级协同优化体系。该体系以系统性降低时间常数 τ 为目标，旨在驱动各层级性能、能效、晶体管密度的持续提升：

- 器件层面：通过优化晶体管和互连电阻及寄生电容，从物理底层最大限度缩微器件级时间常数 τ ；
- 电路层面：通过逻辑折叠技术突破传统平面布局的物理边界，显著缩短关键路径的走线长度并有效降低信号传播的电阻和电容负载，实现晶体管密度和电路性能大幅提升；
- 芯片层面：通过“软件、架构、芯片”的全栈软硬芯协同设计，基于实际工作负载实现指令流和数据流的细粒度控制，提高系统级并行度和效率，大幅降低端到端执行时间；
- 系统层面：定义灵衢总线，重构计算系统互联协议，实现超节点的统一内存编址和原生内存语义，大幅降低系统通信时延。

华为韬定律

156.00 今开 136.00 最高 157.60 最低 136.00
18.78% 24.67 换手 12.61% 总手 252.2万 金额 372.5亿
总值 1.25万亿 流值 3119亿 市盈 229.59 [更多](#)

H股报价: 79.850 7.61% (A/H)比价=2.26 >

盘后固定价格: 156.00 量: 198 额: 308.9万盘后分时

分时 五日 日K 周K 月K 更多 > 设置

均线 MA5:133.44 ↑ MA10:126.56 ↑ MA20:121.78 ↑ DK点 前复权




这份“降成本”秘籍请收好! VIP融资利率通道>> | X


Background



- Challenges:
 - 算力墙: 模型参数从百亿增至万亿级, 单颗 AI 芯片算力增长趋缓, 大规模并行效率受通信开销严重制约
 - 内存墙: 单节点 HBM 容量有限 (128GB/颗), KV Cache 等中间数据爆炸式增长, 成为模型规模扩展的硬性约束
 - 能效墙: 数据频繁搬运导致能耗激增, 传统架构下大量算力浪费在数据移动而非计算上
- 传统架构:
 - 传统以 CPU 为中心的分层架构中, 跨节点通信依赖低速网络, 数据需在 CPU 内存与 NPU 显存间多次中转. NPU 算力利用率常因数据等待而降至 30%-50%, 大量昂贵算力被浪费在数据搬运上. 业界亟需一种能够打破单机内存边界、实现全局内存资源共享的新型架构

模型增长趋势





- 核心规格:


- 384 颗昇腾 910C NPU; 192 颗鲲鹏 920 CPU; BF16 算力 300 PFLOPS; HBM 高带宽内存 48TB

- 网络平面:
 - UB Plane - Scale-Up 纵向扩展
 - 无阻塞全对全拓扑, 每 NPU >392GB/s 单向带宽, 跨节点带宽衰减 <3%, 延迟增加 <1 μ s
 - NC Plane - Scale-Out 横向扩展
 - RoCE 技术, 每 NPU 400Gbps 单向带宽, 负责跨超节点通信, 隔离控制与存储流量
 - VPC Plane - 管理控制与存储
 - 标准以太网/IP, 每节点 400Gbps, 负责部署监控、OBS/EVS/SFS 存储访问
- 核心理念:
 - “一切可池化、一切皆对等、一切可组合”. 通过 UB 网络, 384 个 NPU 和 192 个 CPU 在逻辑上构成一个紧密耦合的大规模逻辑节点

Design



MemFabric Architecture



- 设计目的与核心思想:
 - 异构设备的统一池化: 将多节点的异构设备内存 (DRAM|HBM 等)池化, 提供高性能的全局内存“直接访问”的能力
 - 简单的北向接口: 提供内存语义访问接口, 即 xcopy with global virtual address, 向传统的 memcpy 概念靠近, 支持 D2RH, RH2D, RH2H, D2D 等
 - 南向高可扩展: 通过插件的方式支持多种 DMA 引擎和 LD/ST 及多种网络/灵衢互联 (Device UB、Device RoCE、Host UB、Host RoCE 等)

- Application:
 - 提供对象级语义 (Put/Get 接口), 面向上层应用, 屏蔽底层内存管理的复杂性
- Runtime:
 - 提供统一编址的内存语义, 全局虚拟地址空间 (GVA), 跨节点跨介质直接访问
- Hardware:
 - 支持多种互联协议, Device UB / Device RoCE / Host UB / Host RoCE 等, 高可扩展的插件架构

Design 1: Global Virtual Address




中国科学院计算技术研究所
INSTITUTE OF COMPUTING TECHNOLOGY, CHINESE ACADEMY OF SCIENCES

- 所有进程地址一致, GVA 起始地址全局统一
- 线性排布, uint64 简单地址空间
- 透明访问, 无需关注节点与介质
- 类 memcpy 接口, xcopy(dest, src, n)

Design 1: Global Virtual Address





中国科学院计算技术研究所
INSTITUTE OF COMPUTING TECHNOLOGY, CHINESE ACADEMY OF SCIENCES



Design 2: 跨机跨介质直接访问

- 基于 MemFabric 内存语义统一编址, 数据可以在跨节点的多级存储间实现透明、直接访问
- 典型跨节点跨介质的访问路径有:
 - D2RH: 本机 HBM 到跨机 DRAM
 - RH2D: 跨机 DRAM 到本机 HBM
 - RH2H: 跨机 DRAM 到本机 DRAM





Takeaways & Discussion

- 硬件趋势:
 - CloudMatrix384 的重点是全互联和资源池化, 不只是堆更多 NPU
- 抽象趋势:
 - MemFabric 用 GVA + xcopy, 把远端 HBM/DRAM 变成可被应用直接表达的内存资源
- 系统机会:
 - KV Cache、Embedding、参数缓存等 memory-intensive workload 会最先受益
- 研究空间:
 - placement、prefetch、consistency、runtime scheduling 仍需要 workload-aware design

Thank you!

https://gitcode.com/Ascend/memfabric_hybrid

Q & A